

# Apprentissage par Renforcement pour la Modélisation de Pandémie

Modèle SEIRD & Optimisation des Politiques Sanitaires

Charles Sutty & Martin Reix

École des Mines de Nancy — 4A


Février 2026

# Sommaire

- 1 Introduction
- 2 Modélisation du problème
- 3 Résolution par Reinforcement Learning
- 4 Heuristiques de référence
- 5 Évaluations & Résultats
- 6 Analyse économique
- 7 Conclusion


# Contexte

- Pandémie du **Covid-19** : crise sanitaire mondiale




# Contexte

- Pandémie du **Covid-19** : crise sanitaire mondiale
- Mesures gouvernementales : **confinement** et **vaccination**




# Contexte

- Pandémie du **Covid-19** : crise sanitaire mondiale
- Mesures gouvernementales : **confinement** et **vaccination**
- Compromis fondamental entre :
  - Pertes humaines
  - Pertes économiques
  - Libertés individuelles



# Contexte

- Pandémie du **Covid-19** : crise sanitaire mondiale
- Mesures gouvernementales : **confinement** et **vaccination**
- Compromis fondamental entre :
  - Pertes humaines
  - Pertes économiques
  - Libertés individuelles
- Peut-on utiliser le **Reinforcement Learning** pour guider les politiques publiques ?



# Objectifs du projet

## Objectif principal

Comparer différentes approches de **RL** pour optimiser simultanément confinement et vaccination dans un modèle épidémiologique réaliste.


### Approche

- ① Modélisation SEIRD
- ② Fonction de coût multi-objectif
- ③ Algorithmes : SARSA, Q-Learning, DP
- ④ Comparaison avec heuristiques

### Défis

- Espace d'états continu
- Compromis économie / santé
- Stabilité des politiques
- Réalisme des paramètres

# Le modèle SEIRD



**S** : Susceptibles    **E** : Exposés  
**I** : Infectés    **R** : Rétablis  
**D** : Décédés

Conservation :  $N = S + E + I + R + D = 1$   
 $v(t) = \min(u_{\text{vacc}} \cdot v_{\max}, S(t))$

# Équations du modèle

## Dynamique SEIRD

$$\frac{dS}{dt} = -\beta(1 - u_{\text{conf}})SI - v(t)$$

$$\frac{dE}{dt} = \beta(1 - u_{\text{conf}})SI - \sigma E$$

$$\frac{dI}{dt} = \sigma E - \gamma I$$

$$\frac{dR}{dt} = \gamma(1 - \mu)I + v(t)$$

$$\frac{dD}{dt} = \gamma\mu I$$

## Paramètres :

- $\beta$  : taux de transmission
- $\sigma$  : taux d'incubation ( $1/7 \text{ j}^{-1}$ )
- $\gamma$  : taux de guérison ( $1/10 \text{ j}^{-1}$ )
- $\mu$  : taux de mortalité (1%)

## Contrôles :

- $u_{\text{conf}} \in [0, 1]$  : confinement
- $u_{\text{vacc}} \in [0, 1]$  : vaccination

## Taux de reproduction

$$R_0 = \beta/\gamma \approx 2.7$$

# Fonction de coût

On cherche à minimiser le coût total à chaque pas de temps :

$$\mathcal{L}(s_t, a_t)$$

$$\mathcal{L} = \underbrace{C_{\text{eco}} \times u_{\text{conf}}^2}_{\text{Coût économique}} + \underbrace{C_{\text{vacc}} \times \frac{v(t)}{v_{\max}}}_{\text{Coût logistique}} + \underbrace{C_{\text{vie}} \times \Delta D}_{\text{Pertes humaines}} + \underbrace{C_{\text{hosp}} \times I_t}_{\text{Coût hospitalier}}$$

$\mathcal{L}_{\text{eco}}$   
Confinement<sup>2</sup>

$\mathcal{L}_{\log}$   
Vaccination

$\mathcal{L}_{\text{décès}}$   
Décès  $\Delta D$

$\mathcal{L}_{\text{hosp}}$   
Infectés  $I$

**Note :** Le coût du confinement est **quadratique** — un confinement modéré coûte peu, un confinement total est très coûteux (systèmes critiques).

# Paramètres économiques

Estimations basées sur les données du Covid-19 en France :

Paramètre	Valeur réelle	Normalisée
$C_{\text{eco}}$ (perte éco. / jour)	$30\% \times 6,5 \text{ Md}\text{\euro} \approx 2 \text{ Md}\text{\euro}$	1,0
$C_{\text{vie}}$ (par décès)	3 M€ / personne	≈ 1000
$C_{\text{vacc}}$ (logistique totale)	3,5 Md€	0,02
$C_{\text{hosp}}$ (par infecté / jour)	580 € / patient / jour	≈ 20

## Sources

- OFCE (2020) — impact sur le PIB
- INSEE — PIB pré-pandémie
- Valeur statistique d'une vie (gouv.)
- Coûts hospitalisation Covid

## Normalisation

Toutes les valeurs sont normalisées par  $C_{\text{eco}}$  pour la stabilité numérique des algorithmes.

# Discrétisation de l'espace

Discrétisation des états (bins) :

- **Susceptibles ( $S$ )** : 12 bins, découpage non-uniforme  
 $[0, 0.2, 0.4, 0.6, 0.7, 0.8, 0.85, 0.9, 0.93, 0.95, 0.97, 0.985, 1.0]$
- **Exposés ( $E$ ) et Infectés ( $I$ )** : 12 bins, échelle logarithmique  
 $[0, 10^{-5}, 3 \times 10^{-5}, 10^{-4}, 3 \times 10^{-4}, 10^{-3}, 3 \times 10^{-3}, 10^{-2}, 3 \times 10^{-2}, 0.1, 0.3, 0.5, 1.0]$

Espace d'états ( $S, E, I$ )

$$12^3 = 1\,728 \text{ états}$$

Espace d'actions

$$5 \times 5 = 25 \text{ actions par état}$$

$$u \in \{0, 0.25, 0.5, 0.75, 1\}$$

Pourquoi une échelle logarithmique ?

L'épidémie évolue de manière exponentielle. Une discrétisation logarithmique pour  $E$  et  $I$  permet de capturer avec précision les dynamiques critiques lorsqu'une faible partie de la population est infectée.

# Algorithmes d'apprentissage

## SARSA (*on-policy*)

- ① Choisir  $a$  par  $\epsilon$ -greedy
- ② Exécuter  $a$ , observer  $r, s'$
- ③ Choisir  $a'$  par  $\epsilon$ -greedy
- ④ Mise à jour :

$$Q(s, a) += \alpha [r + \gamma Q(s', a') - Q(s, a)]$$

Met à jour avec l'action **réellement choisie**

## Q-Learning (*off-policy*)

- ① Choisir  $a$  par  $\epsilon$ -greedy
- ② Exécuter  $a$ , observer  $r, s'$
- ③ Mise à jour :

$$Q(s, a) += \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$


Met à jour avec l'action **optimale**

## Programmation Dynamique approchée

Deux variantes : **Itération de la politique** et **Itération de la valeur** avec estimation Monte-Carlo des transitions.

$$V_t(s) = \max_a (\hat{\mathbb{E}}[r(s, a, S')] + \gamma \hat{\mathbb{E}}[V_{t+1}(S')])$$

# Courbes d'entraînement



- Les deux algorithmes convergent en  $\sim 5\ 000$  épisodes
- Q-Learning présente une convergence plus stable
- La récompense cumulée se stabilise, signe de convergence de la politique

# Quatre politiques de référence

- Aucun contrôle

$$u_c = 0, u_v = 0$$

Borne supérieure du coût. Scénario « Brésil ».

- Vaccination max

$$u_c = 0, u_v = 1$$

Effet de la vaccination seule. Coût logistique max.

- Confinement par seuil

$$u_c = \mathbb{1}_{I>0.02}, u_v = 0.5$$

Réaction « tout ou rien ». Premiers confinements français.


- Double seuil adaptatif

$$u_c \text{ gradué} + u_v \text{ adapté à } S(t)$$

Confinement progressif + vaccination ciblée. La plus réaliste.




# Politiques des heuristiques




- Aucun contrôle → rien à signaler, taux nuls
- Vaccination max → vaccination à taux plein

# Politiques des heuristiques



- Confinement par seuil  $\Rightarrow$  oscillations de  $\sim 10$  jours
- Double seuil  $\Rightarrow$  transitions plus souples, vaccination agressive puis relâchée


# Évolution SEIRD — Heuristiques



Sans contrôle / Vacc. seule

Croissance rapide des infectés. Vacciner seul est insuffisant.


# Évolution SEIRD — Heuristiques



Seuil / Double seuil


Infectés bien plus faibles, mais épidémie plus longue.

# Politiques des algorithmes RL




- Politiques **agressives** : oscillations entre confinement total et nul
  - **SARSA** : confinement fort en début, puis vaccination intensive
  - **Q-Learning** : confinement fort + vaccination plus tardive
- Manque de contrainte de *lissage* dans l'espace d'actions

# Évolution de l'épidémie — Comparaison globale




- Sans contrôle : impact le plus dévastateur
- SARSA et Q-Learning : les plus **prudents** en termes de décès
- DP approché : résultats proches du laisser-faire (complexité du problème)

# Évolution SEIRD — Algorithmes




- Le pic des exposés (*E*) précède celui des infectés (*I*)  $\Rightarrow$  confirmation de la dynamique d'incubation
- SARSA/Q-Learning : pertes humaines minimisées au détriment de l'économie

# Évolution SEIRD — Algorithmes



- DP Learning → très similaire à aucun contrôle, probablement dû à un problème d'implémentation

# Coûts financiers par scénario



Meilleur compromis

**Double seuil adaptatif** : limite à la fois les pertes humaines, l'hospitalisation et les pertes économiques.

RL : compromis différent

SARSA et Q-Learning privilégient les vies humaines au détriment de l'économie  $\Rightarrow$  choix éthique.

## Synthèse comparative

Politique	Décès	Coût éco.	Coût hosp.	Réalisme
Aucun contrôle	↑↑↑	↓	↑↑↑	★
Vaccination max	↑↑	↓	↑↑	★★
Seuil	↑	↑↑	↑	★★
<b>Double seuil</b>	↓	↑	↓	★★★
SARSA	↓↓	↑↑	↓↓	★★
Q-Learning	↓↓	↑↑	↓↓	★★
DP approché	↑↑	↓	↑↑	★

↑ = élevé (mauvais), ↓ = faible (bon)

\* = réalisme de la politique

# Conclusion

## Résultats clés

- Le modèle SEIRD capture bien les dynamiques épidémiques
- Les algorithmes RL **minimisent les décès** mais au prix de politiques **erratiques**
- Le **double seuil adaptatif** offre le meilleur compromis global
- Le choix final relève de **décisions éthiques et politiques**

## Pistes d'amélioration

- Contrainte de **lissage** des actions
- Capacité hospitalière **maximale**
- Algorithmes **Deep RL** (DQN, PPO)
- Modèle **stochastique** (aléas réels)
- Prise en compte des **variants**

## Code source

<https://github.com/Charsutty/RL-pandemic-modeling>

# Merci de votre attention !

Questions ?

Charles Sutty & Martin Reix

[https://github.com/Charsutty/  
RL-pandemic-modeling](https://github.com/Charsutty/RL-pandemic-modeling)

# Références I

-  Jianhong Wu, Kathy Leung, and Gabriel Leung.  
Nowcasting and forecasting the potential domestic and international spread of the 2019-ncov outbreak originating in wuhan, china : A modeling study.  
*Obstetrical & Gynecological Survey*, 75 :399–400, 07 2020.
-  Fernando E Alvarez, David Argente, and Francesco Lippi.  
A simple planning problem for covid-19 lockdown.  
Working Paper 26981, National Bureau of Economic Research, 4 2020.
-  Regina Padmanabhan, Nader Meskin, Tamer Khattab, Mujahed Shraim, and Mohammed Al-Hitmi.  
Reinforcement learning-based decision support system for covid-19.  
*Biomedical Signal Processing and Control*, 68 :102676, 2021.
-  Ofce Observatoire Français Des Conjonctures Économiques.  
Évaluation au 30 mars 2020 de l'impact économique de la pandémie de COVID-19 et des mesures de confinement en France.  
*OFCE Policy Brief*, (65) :, March 2020.

## Annexe — Paramètres épidémiologiques détaillés

Symbol	Signification	Valeur	Source
$\Delta t$	Pas de temps	1 jour	—
$\sigma$	Taux d'incubation	$1/7 \approx 0.14$	Littérature
$\gamma$	Taux de guérison	$1/10 = 0.1$	Littérature
$R_0$	Taux de reproduction	2.7	Littérature
$\beta$	Taux de transmission	0.27	$R_0 \times \gamma$
$\mu$	Taux de mortalité	0.01	Littérature
$v_{\max}$	Cap. logistique vacc.	0.001 / jour	Estimation

## Annexe — Double seuil adaptatif (détail)

### Confinement gradué

$$u_{\text{conf}}(t) = \begin{cases} 0.75 & \text{si } I(t) > 0.02 \\ 0.25 & \text{si } 0.005 < I(t) \leq 0.02 \\ 0 & \text{sinon} \end{cases}$$

### Vaccination adaptée

$$u_{\text{vacc}}(t) = \begin{cases} 1 & \text{si } S(t) > 0.3 \\ 0.25 & \text{sinon} \end{cases}$$

**Principe :** Confinement progressif pour limiter le coût économique + vaccination concentrée quand  $S$  est grand, réduite ensuite.